

Variable	Mean	Median	Mode	Minimum	Maximum	Data Range	Standard Deviation
NOPAT	2.36E+10	2.36E+10	-1.2E+09	-1.2E+09	4.9E+10	5.02E+10	1.45E+10
بالاعتماد على القيمة السوقية WACC	0.025	0.025	-0.017	-0.027	0.077	0.104	0.03
رأس المال المستثمر بالاعتماد على القيمة السوقية	1.97E+11	1.97E+11	2.81E+11	1.78E+10	3.8E+11	3.62E+11	1.04E+11

variable	Mean	Median	Mode	Minimum	Maximum	Data Range	Standard Deviation
X1	0.462	0.463	-0.023	-0.023	0.949	0.972	0.281
X2	-0.03	-0.03	-0.1	-0.1	0.04	0.14	0.04
X3	-0.26	-0.262	-0.96	-0.96	0.442	1.402	0.405
X4	0.275	0.274	0.01	0.01	0.54	0.53	0.153
X5	8.175	8.177	1.3	1.3	15	13.699	3.953
X6	0.028	0.028	0.001	0.001	0.055	0.054	0.015
X7	6.992	6.978	0.04	0.04	14	13.96	4.038
X8	0.13	0.13	0.01	0.01	0.25	0.24	0.069
X9	0.145	0.144	0.001	0.001	0.29	0.289	0.084

1 الجدول: الاحصائيات الخاصة بالبيانات المولدة

2 الجدول: الاحصائيات الخاصة بالبيانات الأساسية

دراسة وتحليل مجموعة البيانات الخاصة بالبيانات الأساسية:

تم استخدام داتا سيت تشمل ثمانية وثمانون حالة حيث تمثل كل حال مصرف مالي ما وتحتوي هذه الحالة خصائص المصرف حيث لدينا ثمانية وثمانون سطر وعشرة أعمدة تمثل خصائص المصرف والسطر الواحد يمثل المصرف.

شرح الأعمدة:

1. **العمود X1:** يمثل نسبة السيولة القانونية، وهو من نوع float.
2. **العمود X2:** يمثل معدل العائد على الأصول ROA يقدم هذا المؤشر معلومات عن كفاءة الإدارة في استخدام الأصول لتوليد الدخل، ويُحسب من نسب صافي الدخل بعد الضريبة إلى إجمالي الأصول، وهو من نوع float.
3. **العمود X3:** يمثل معدل العائد على حقوق الملكية ROE يُعبر هذا المؤشر عن الأداء الكلي للمصرف بما فيه التشغيلي و المالي، ويقيس مدى تحقيق الهدف الذي تسعى إليه الإدارة المالية إلا وهو تعظيم ثروة المساهمين، ويمكن حسابه بنسب صافي الدخل إلى حقوق الملكية، وهو من نوع float.
4. **العمود X4:** يمثل كفاية رأس المال يمكن تعريف كفاية رأس المال على أنها مقدار رأس المال الذي يتحقق عنده التوازن بين حجم رأس المال و المخاطر التي يتوقعها المصرف، وهو من نوع float.
5. **العمود X5:** يمثل حجم المصرف يعتبر حجم المصرف أحد أهم العوامل المؤثرة في الربحية ويمكن التعبير عنه بعدة طرق منها: إجمالي الأصول أو إجمالي حقوق الملكية...إلخ، وهو من نوع float.
6. **العمود X6:** يمثل نسبة الفوائد المدينة إلى الودائع والتي تعكس نسبة ما يتحمله المصرف من أعباء الفائدة، وهو من نوع float.
7. **العمود X7:** يمثل نسبة الفوائد الدائنة إلى القروض والتي تعكس نسبة ما يربحه المصرف من الإقراض، وهو من نوع float.
8. **العمود X8:** يمثل نسبة تركيز الودائع وتحسب من نسب إجمالي الودائع التي حصل عليها المصرف في سنة معينة من إجمالي الودائع التي قام المودعون فيها ضمن الجهاز المصرفي بشكل كامل، وهو من نوع float.
9. **العمود X9:** يمثل نسبة تركيز القروض وتحسب من نسب إجمالي القروض التي قام بها المصرف في سنة معينة من إجمالي القروض التي قامت جميع المصارف بها ، وهو من نوع float.

10. **العامود Y:** يمثل المتغير التابع يمثل القيمة الاقتصادية المضافة EVA ، وهو من نوع Boolean.


عينة بيانات التدريب:

لتسهيل التعامل مع البيانات سوف نقوم بإنشاء ملف CSV يحوي على قيم المتحولات المستقلة من 1 إلى 9 وعلى قيم المتغير التابع (القيمة الاقتصادية المضافة EVA) وهو عبارة عن قيم (a,b) حيث b تعبر عن الأداء السيء للمصرف و a تعبر عن الأداء الجيد للمصرف وتم استنتاج هذا الأداء من خلال العلاقة الرياضية التالية: $EVA = NOPAT - (WACC * IC)$ تم ترميز قيم المتغير التابع ب (0,1) لتسهيل التدريب على الشبكة العصبية.

X1	X2	X3	X4	X5	X6	X7	X8	X9	Y
0.371	-0.01614	-0.13189	0.22896	6.91344	0.03506	0.28139	0.09998	0.06818	b
0.4336	-0.07702	-0.74616	0.15058	8.24828	0.03518	0.24343	0.09542	0.06892	b
0.4319	-0.04607	-0.35272	0.12613	6.33257	0.02861	8.66057	0.10026	0.00192	b
0.5324	-0.07739	-0.50865	0.07658	5.30541	0.01744	16.9376	0.1322	0.00102	a
0.5629	-0.07021	-0.32136	0.057	3.35107	0.01991	26.7458	0.12378	0.00082	a
0.5389	0.06925	0.34289	0.05607	3.76729	0.02497	34.0712	0.11437	0.00067	b
0.6455	0.01298	0.07568	0.09682	4.51465	0.02902	18.6429	0.11675	0.00107	a
0.4814	0.02139	0.13797	0.06756	5.21516	0.02769	17.1646	0.062	0.00148	b
-0.0228	-0.16157	-0.61449	0.03887	2.68282	0.0201	3.35418	0.11292	0.00771	a
0.5463	-0.1412	-0.52455	0.02796	0.23869	0.15204	0.14567	0.00659	0.06764	a
0.4355	-0.03193	-0.1034	0.02173	2.15497	0.02072	0.14391	0.07882	0.0623	a
0.2175	-0.01733	-0.12131	0.2258	5.85709	0.05506	0.14826	0.05311	0.08956	a
0.2423	-0.10778	-0.74828	0.25339	5.75395	0.06011	0.08574	0.03654	0.0782	b

الشكل 0—1 البنية التي سيتم التعامل معها للوصول للبيانات

تم حساب عدد المصارف التي حققت أداء جيد وعدد التي حققت أداء سيء ونسبة المصارف ذات الأداء الجيد و السيء في مجموعة البيانات قبل البدء في التدريب وفي الاشكال التالية تم توضيح هذه الحسابات.



الشكل 0—2 نسبة أداء المصارف جيد أو سيء

الشكل 0—1 عدد المصارف ذات الأداء الجيد و السيء

تطبيق نموذج التدريب:

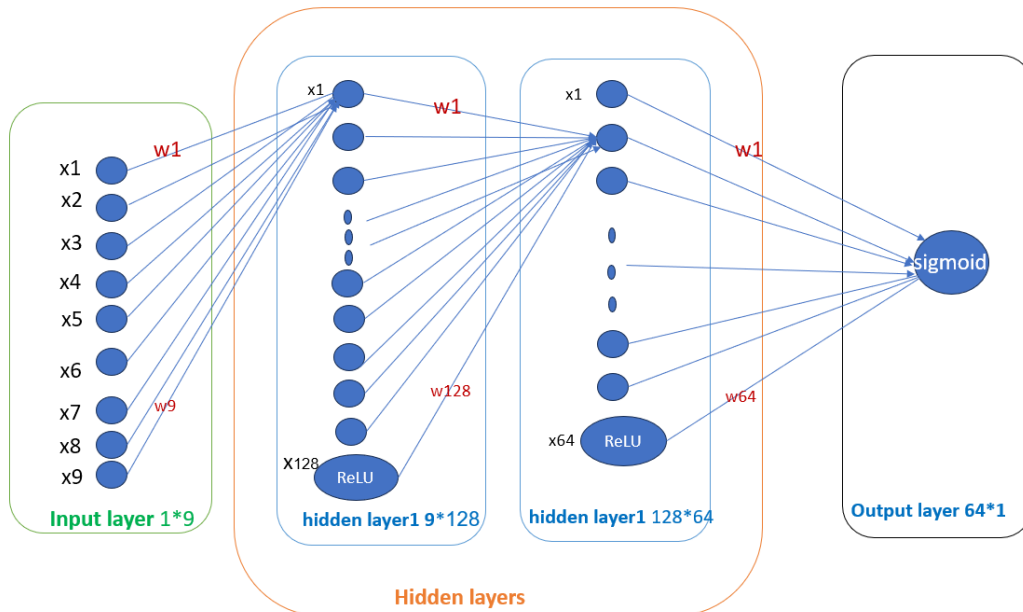
تم تدريب مجموعة البيانات باستخدام خوارزمية DNDF (Deep Neural decision forest) حيث يقوم النموذج بتدريب نموذج شبكة عصبية باستخدام Keras على بيانات التدريب.

ثم يقوم باستخراج الميزات من الطبقة قبل الأخيرة لنموذج الشبكة العصبية لكل من بيانات التدريب والاختبار.

بدلاً من تدريب Random Forest Classifier بشكل منفصل، فهو يجمع بشكل مباشر بين الشبكة العصبية وأساليب شجرة القرار باستخدام الميزات المستخرجة من الشبكة العصبية كمدخلات إلى Random Forest Classifier.

مراحل إنشاء النموذج:


1. **تهيئة بيانات التدريب:** بما أن جميع أعمدة مجموعة البيانات ماعدا آخر عامود هي ارقام عشرية فلا يوجد حاجة لمعالجتها او التعديل عليها، أما بالنسبة لآخر عامود فهو يحوي على قيم (a,b) لذلك تم معالجة هذا العامود من خلال ترميزه بتحويل القيمة a الى 1 و القيمة b الى 0 .
2. **تقسيم العينات للتدريب والاختبار:** تم اعتماد تقسيم العينات بنسبة 70:30 وبالتالي 61 سطر لبيانات التدريب و 27 للبيانات التدريب وتم اختيار البيانات بشكل عشوائي في كل مجموعة.
3. **تعريف بنية نموذج الشبكة العصبية العميقة DNN:** حيث تتألف من طبقة دخل وطبقتين خفيتين وطبقة خرج وفيما يلي شرح تفصيلي للطبقات الشبكة:



الشكل 0-1 نموذج الشبكة العصبية

- **طبقة الدخل input layer:** تحتوي طبقة الإدخال على 9 خلايا عصبية، وهو عدد الميزات الموجودة في خصائص المصرف وهي المتحولات من 1 الى 9. وترتبط كل خلية عصبية في طبقة الإدخال بكل خلية عصبية في الطبقة التالية.
- **طبقة الخفية الأولى hidden layer 1:** تحتوي على 128 خلية عصبية، وكل خلية من هذه الخلايا العصبية تتلقى مدخلات من جميع الخلايا العصبية في طبقة الإدخال. تأخذ كل خلية عصبية في هذه الطبقة المدخلات من الطبقة السابقة وتحسب الوزن الخاص لهذه الخلية. ويتبع ذلك تطبيق تابع التنشيط ReLU من لحساب قيمة خرج هذه الخلية.
- **طبقة الخفية الثانية hidden layer 2:** تقوم بنفس عمل الطبقة السابقة وتحتوي على 64 خلية عصبية، يتم توصيل كل خلية عصبية في الطبقة الخفية الاولى مع كل خلية عصبية في الطبقة الخفية الثانية، وهكذا حتى طبقة الإخراج النهائية.
- **طبقة الخرج output layer:** تحوي هذه الطبقة على خلية عصبية واحدة، تحسب الخلية العصبية المفردة في هذه الطبقة مجموع الاوزان لمدخلات هذه الطبقة وتطبق تابع التنشيط sigmoid.

4. **توابع التنشيط activation function:** تم استخدام في الطبقات الخفية، تابع التنشيط عبارة عن تابع رياضي يستخدم في الشبكات العصبية للحصول على ناتج العقدة (العصبون). حيث يقوم بتعيين القيم الناتجة من العقدة الي قيمة بين 0 إلى 1 أو -1 إلى 1 وما إلى ذلك (حسب نوع تابع التنشيط). سنتحدث في هذه الفقرة عن أنواع توابع التنشيط المستخدمة في نموذجنا:
- **ReLU function:** هو تابع التنشيط الأكثر استخداما في العالم في الوقت الحالي، حيث يتم استخدامه تقريبا في جميع الشبكات العصبية التلافيفية CNN أو التعليم العميق Deep learning. ويتم تمثيله بالعلاقة التالية: $f(x) = \max(0, x)$




الشكل 0—ReLU function2

- **Sigmoid function**: تم استخدام في طبقة الخرج, يبدو منحنى التابع على شكل حرف S. السبب

الرئيسي وراء استخدامنا لتابع السيغمود هو وجوده بين (0 الى 1). لذلك يتم استخدامه بشكل خاص للنماذج التي يتوجب عليها توقع قيمة احتمالية كخرج للشبكة كما في نموذجنا. نظرا لأن احتمال أي شيء موجود فقط بين النطاق 0 و 1، فإن تابع السيجمود هو الاختيار الصحيح. ويعطى بالعلاقة


$$f(x) = \frac{1}{1+e^{-x}}$$



الشكل 0-3 Sigmoid function

5. **تابع التحسين المستخدم**: في التعلم العميق، تعد خوارزميات التحسين مكونات حاسمة تساعد الشبكات العصبية على التعلم بكفاءة والوصول إلى الحلول المثلى. إحدى خوارزميات التحسين الأكثر شيوعاً المستخدمة في تدريب الشبكات العصبية العميقة والتي تم استخدامها لهذا النموذج هي مُحسِن Adam.

6. **استخراج المزايا features extraction**: يلعب استخراج الميزات دوراً محورياً في تحويل البيانات الأولية إلى نموذج أكثر قابلية للتحليل والتفسير بواسطة نماذج التعلم الآلي. ويمكن استخراج الميزات النماذج من الكشف عن الأنماط المخفية، وإجراء تنبؤات دقيقة.



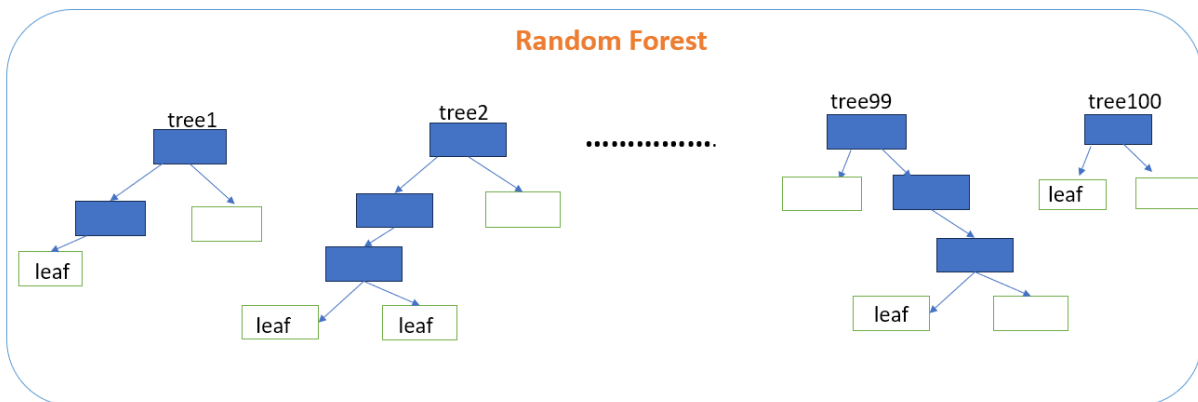
الشكل 0-4 features extraction model

تم إنشاء شبكة عصبية تمثل نموذج استخراج المزايا حيث يمتلك طبقة دخل نفس طبقة الدخل في شبكة العصبية التي تم أنشائها مسبقاً أما طبقة الخرج هي نفس الطبقة الثانية للشبكة السابقة والهدف من هذا النموذج هو استخراج مزايا تكون دخل للأشجار القرار.

7. غابة القرار **decision forest or Random Forest**: هي خوارزمية تعلم آلي مستخدمة على نطاق واسع تم تطويرها بواسطة **Leo Breiman** و **Adele Cutler**، والتي تجمع بين مخرجات أشجار القرار المتعددة للوصول إلى نتيجة واحدة. لقد عززت سهولة استخدامه ومرونته من اعتماده، حيث إنه يتعامل مع مشاكل التصنيف والانحدار.

تم استخدام الصف `sklearn. ensemble. RandomForestClassifier` حيث تم تحقيق الغابات العشوائية ضمن مكتبة `sklearn` وتم تحديد دخل الغابة على أنه خرج نموذج استخراج المزايا وهو عبارة عن مصفوفة بحجم $n*m$ حيث n تمثل حجم بيانات التدريب ، m تمثل حجم المزايا المستخرجة من الطبقة الخفية الثانية وخرج هذه الغابة هو $n*1$ وهو التصنيف الخاص بكل عينة من عينات التدريب وتم اعتماد قيم المعلمات (hyper parameters) كما يلي:

- عدد أشجار القرار **$n_estimators$** : وهو يمثل عدد الأشجار في الغابة وقيمته 100.
- **$min_samples_split$** : الحد الأدنى لعدد العينات المطلوبة لتقسيم العقدة الداخلية في الشجرة وقيمته 2.
- **$max_samples$** : الحجم الجزئي للبيانات المخصصة لكل شجرة ضمن الغابة وهو من نوع `integer` وقيمته `None`.
- **`Bootstrap`**: وهو من نوع `Boolean` حيث إذا كانت القيمة `False`، فسيتم استخدام مجموعة البيانات بأكملها لبناء كل شجرة وإذا كانت القيمة `True` سيتم أخذ بيانات من مجموعة البيانات الأساسية بحجم **$max_samples$** وبما أن قيمة **$max_samples$** هي `None` فسيتم استخدام مجموعة البيانات بأكملها لبناء كل شجرة.



الشكل 0-5 غابة القرار

8. النتائج والمراقبة:

- **training loss** : يعد مقياساً لمدى جودة أداء نموذج التعلم الآلي على بيانات التدريب. يتم حسابه أثناء عملية التدريب ويستخدم لتحديث معلمات النموذج من خلال تقنيات مثل Gradient descent لتقليل هذه الخسارة. وينبغي أن ينخفض بمرور الوقت أثناء تعلم النموذج من البيانات. وتابع الخسارة المستخدم هو entropy loss function، حيث p_i هو احتمال الصنف 1، و $(1-p_i)$ هو احتمال الصنف 0. ويعطى بالعلاقة التالية:


$$\text{Log loss} = \frac{1}{N} \sum_{i=1}^N - (y_i * \log(p_i) + (1-y_i) * \log(1-p_i))$$

الشكل 6—entropy loss equation


- **validation loss**: يعد مقياساً لمدى جودة أداء نموذج التعلم الآلي على مجموعة بيانات منفصلة عن بيانات التدريب تسمى validation set. أثناء التدريب، يتم وضع جزء من البيانات (غير المستخدمة للتدريب) جانباً كمجموعة التحقق من الصحة يتم تقييم أداء النموذج في مجموعة التحقق بشكل دوري (بعد كل epoch)، ويتم حساب validation loss. يساعد validation loss في تقييم مدى جودة تعميم النموذج على البيانات التي لم يراها أثناء التدريب على غرار validation loss، يتم حساب خسارة التحقق باستخدام دالة entropy loss function.

تم اختبار مجموعة البيانات ذات الحجم 88 على النموذج السابق وحقق النتائج التالية:

عند epoch = 40 حقق accuracy = 55.74% موضحة بالشكل التالي:




الشكل 8—training and validation loss




الشكل 7—training and validation accuracy

- عند epoch = 80 حقق $\text{accuracy} = 70.49\%$ موضحة بالشكل التالي:



الشكل 9-0 training and validation loss



الشكل 10-0 training and validation accuracy

وبما أن هذه النتائج تعتبر نتائج سيئة وغير مقبولة واكتشفنا أن السبب الرئيسي لهذه النتائج السيئة هو حجم بيانات التدريب الذي يعتبر قليل جدا نظرا للمشكلة التي على النموذج حلها لذلك كان من الضروري إيجاد حل لهذه المشكلة، وكان الحل هو الحصول على مجموعة بيانات جديدة ذات حجم كبير مقارنة بحجم البيانات السابقة. و ذلك من خلال توليد مجموعة البيانات باتباع شروط وقيود تخص كل عامود (متحول) في مجموعة البيانات المولدة وفق ما يلي :

1. توليد المتحولات ($x_1 \dots x_9$) ولذلك باتباع الخطوات التالية:

- حساب الاحصائيات الخاصة بمجموعة البيانات الأساسية ومعطاة بالشكل التالي:

variable	Mean	Median	Mode	Minimum	Maximum	Data Range	Standard Deviation
X1	0.463	0.453	0.453	-0.023	0.949	0.972	0.194
X2	-0.038	-0.016	-0.267	-0.267	0.085	0.353	0.073
X3	-0.22	-0.134	-1.543	-1.543	0.442	1.984	0.377
X4	0.231	0.155	0.022	0.022	1.258	1.236	0.225
X5	7.224	5.157	0.239	0.239	78.93	78.692	9.738
X6	0.025	0.021	0	0	0.152	0.152	0.019
X7	3.445	0.144	0.018	0.018	152.293	152.275	16.98
X8	0.124	0.099	0.007	0.007	0.368	0.362	0.087
X9	0.125	0.111	0	0	0.471	0.471	0.102

الجدول 3 الاحصائيات الخاصة بمجموعة البيانات الأساسية

- توليد مصفوفة من الأرقام العشوائية بحجم خمسين ألف بحيث تخضع الأرقام في هذه المصفوفة للشرط الأول: $\max x_i > x'_i > \min x_i$ حيث:
- x_i : المتحول الذي يتم توليد قيم عشوائية له.
- x'_i : الرقم الذي تم توليده.
- $\max x_i$: أكبر قيمة للمتحول x_i .
- $\min x_i$: أصغر قيمة للمتحول x_i .

- حساب قيمة z للمصفوفة الأرقام المولدة وفق العلاقة التالية: $z = \frac{\bar{x}_i - \bar{x}'_i}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$ حيث:

- z : يمثل المتحول z .
- \bar{x}_i : المتوسط الحسابي للمتحول x_i للأرقام الأساسية.
- \bar{x}'_i : المتوسط الحسابي للمتحول x'_i للأرقام المولدة.
- s_1^2 : التباين للمتحول x_i للأرقام الأساسية.
- s_2^2 : التباين للمتحول x'_i للأرقام المولدة.
- n_1 : عدد الاسطر في مجموعة البيانات الأساسية وهو 88.
- n_2 : عدد الاسطر في مجموعة البيانات المولدة وهو 50 ألف.
- خضوع المصفوفة المولدة للشرط الثاني التالي: $|z_{xi}| < 1.96$ حيث z_{xi} هي قيمة z للأرقام المولدة.

- ولدينا الجدول التالي الذي يوضح القيم والمتغيرات التي خضعت لها المتحولات (x1...x9) المولدة:

Variable name	ϵ_value	Minimum	Maximum	Z_value	Sig
X1	0.02	-0.023	0.949	-0.02854	0.977
X2	0.03	-0.1	0.04	1.07518	0.285
X3	0.04	-0.96	0.44	-0.98193	0.329
X4	0.30	0.01	0.54	1.84816	0.068
X5	1	1.3	15.0	0.91618	0.362
X6	0.05	0.0013	0.055	1.29389	0.106
X7	4	0.04	14	1.95925	0.053
X8	0.02	0.01	0.25	0.64749	0.519
X9	0.02	0.0008	0.29	1.829	0.071
NOPAT	63.0E+8	-1173870611	49.0E+9	1.930	0.057
WACC	0.01	-0.0272	0.077	1.840	0.069
IC	286.0E+8	17771382489	3.8E+11	1.716	0.09

الجدول 4 المعلمات الداخلة في توليد المتحولات

2. توليد المتحول التابع المعبر عن أداء المصارف EVA وبما أنه يعطى بالمعادلة التالية:
- $$EVA = NOPAT - (WACC * IC)$$
- تم توليد قيمته باتباع الخطوات التالية:
- حساب الاحصائيات الخاصة بـ EVA لمجموعة البيانات الأساسية ومعطاة بالشكل التالي:

Variable	Mean	Median	Mode	Minimum	Maximum	Data Range	Standard Deviation
NOPAT	1.74E+10	1.96E+09	1.4E+11	-5.3E+09	1.4E+11	1.45E+11	3.05E+10
بالاعتماد على القيمة السوقية WACC	0.019	0.012	-0.027	-0.027	0.15	0.178	0.028
رأس المال المستثمر بالاعتماد على القيمة السوقية IC	1.69E+11	1.12E+11	1.78E+10	1.78E+10	7.3E+11	7.12E+11	1.56E+11

الجدول 5 احصائيات EVA للبيانات الأساسية


- وجب علينا توليد متحولات علاقة EVA التي خضعت لنفس الشروط والقيود التي خضعت لها المتحولات المولدة (x1...x9) ولدينا الجدول التالي الذي يوضح القيم والمتغيرات التي خضعت لها الأرقام المولدة:

Variable name	ε_value	Minimum	Maximum	Z_value	Sig
NOPAT	63.0E+8	-1173870611	49.0E+9	1.930	0.057
WACC	0.01	-0.0272	0.077	1.840	0.069
IC	286.0E+8	17771382489	3.8E+11	1.716	0.09


الجدول 6 المعلمات التي دخلت في توليد متحولات EVA

وبذلك تم توليد مجموعة بيانات جديدة وفق القيود السابقة تحتوي على خمسون ألف سطر و 10 أعمدة وأصبحت جاهزة للتدريب شبكة DNN عليها.

تم حساب عدد المصارف التي حققت أداء جيد وعدد التي حققت أداء سيء ونسبة المصارف ذات الأداء الجيد و السيء في مجموعة البيانات المولدة قبل البدء في التدريب وفي الاشكال التالية تم توضيح هذه الحسابات.




الشكل 11—0 نسبة المصارف الجيدة و السيئة




الشكل 12—0 عدد المصارف ذات الأداء الجيد و السيء

3. النتائج والمراقبة الخاصة بمجموعة البيانات المولدة:
- عند epoch = 80 حقق accuracy = 86.69% موضحة بالشكل التالي:



الشكل 14—0 training and validation loss



الشكل 13—0 training and validation accuracy

